

CAHIER DES CHARGES DE TRAVAIL

TP INF232 — Statistiques et Analyse de Données

Thème D : Établissement scolaire secondaire

1. Objectif du document

Ce cahier des charges organise le travail du groupe pour réaliser le TP INF232 sur le thème D. Il précise les tâches à coder, les tâches de documentation, les responsabilités de chaque étudiant, les livrables attendus et le planning à respecter sur deux jours.

NB : chaque étudiant doit écrire du code et doit aussi produire une courte documentation personnelle expliquant précisément ce qu'il a codé, testé et compris.

2. Identification du projet

Élément	Description
Matière	INF232 — Statistiques et Analyse de Données
Thème choisi	Thème D : Établissement scolaire secondaire
Problème étudié	Comprendre les performances d'élèves de terminale à partir d'une évaluation interne, étudier le lien avec le travail personnel, identifier des profils naturels et proposer une orientation automatique.
Langage proposé	Python
Justification du langage	Python est adapté aux statistiques et à l'analyse de données grâce à ses bibliothèques de calcul, de visualisation et de machine learning.
Données	Données synthétiques générées de façon déterministe avec la graine du groupe.
Documents à rendre	1) Application + données générées + mode d'emploi ; 2) Rapport complet illustré.

3. Données à générer

Pour un meilleur test nous aurons besoins d'environ 200 élèves de terminale.

Variable	Signification	Format/Bornes
id_eleve	Identifiant unique de l'élève	E001, E002, ...
note_evaluation	Note obtenue à une évaluation interne de mathématiques/raisonnement scientifique	Nombre entre 0 et 20
heures_travail	Nombre moyen d'heures de travail personnel par semaine	Nombre entre 0 et 25
orientation	Orientation recommandée par le conseil de classe	scientifique ou littéraire

La génération devra introduire une relation plausible : les élèves ayant plus d'heures de travail ont tendance à obtenir une meilleure note, sans que cette relation soit parfaite. L'orientation sera générée avec une part d'aléa contrôlée afin de rendre la classification supervisée réaliste.

4. Mécanisme de génération de la graine

Algorithme :

seed = 0

Pour chaque caractère c à la position i :

 valeur(c) = rang alphabétique de c, avec A=1, ..., Z=26

 seed = (seed * 37 + i * valeur(c)) mod 2147483647

5. Organisation technique de l'application

Chaque module correspond à une partie du TP et à la responsabilité d'un ou plusieurs étudiants.

Fichier/Dossier	Rôle
00_config_seed.py	Normalisation du nom du chef, calcul de la graine, configuration globale
01_generation_donnees.py	Création des données synthétiques et sauvegarde dans data/eleves_theme_D.csv
02_stat_univariee.py	Question 1 : statistiques descriptives et graphiques de la note d'évaluation
03_stat_bivariee.py	Question 2 : corrélation, régression linéaire et limites de prédiction
04_clustering.py	Question 3 : classification non supervisée des profils d'élèves
05_classification_supervisee.py	Question 4 : prédiction de l'orientation scientifique/littéraire
06_visualisations.py	Graphiques propres à insérer dans le rapport

main.py	Script principal qui lance toutes les analyses
README.md	Mode d'emploi pour exécuter le projet
Rapport/	Dossier contenant le rapport final

6. Méthodes statistiques attendues par question

Question	Bloc du cours	Méthodes possibles	Réponse attendue
Question 1	Analyse univariée	Moyenne, médiane, quartiles, écart-type, min/max, valeurs atypiques, histogramme, boîte à moustaches	Expliquer la répartition des notes et signaler les élèves très faibles ou très forts.
Question 2	Analyse bivariée	Nuage de points, coefficient de corrélation, droite de régression, erreur moyenne, limites d'utilisation	Dire si les heures de travail permettent d'anticiper la note et jusqu'où cette anticipation reste sérieuse.
Question 3	Classification non supervisée	Standardisation, K-means ou autre méthode, choix du nombre de groupes, description des centres	Identifier des profils naturels d'élèves indépendamment de l'orientation déjà recommandée.
Question 4	Classification supervisée	Séparation entraînement/test, modèle simple, matrice de confusion, exactitude, précision/rappel	Évaluer si on peut suggérer automatiquement une orientation scientifique ou littéraire.

7. Répartition claire des tâches entre les étudiants

Chaque étudiant doit produire au minimum : 1 fichier de code ou une partie clairement identifiable dans un fichier, 1 court document personnel expliquant son travail, et une preuve de test/résultat obtenu.

N°	Étudiant	Matricule	Responsabilité	Code à écrire	Documentation individuelle
1	KENGNE GUEPOUKSI Pierre Josué	24H2486	Chef + code graine/configuration	Coder 00_config_seed.py : normalisation du nom, calcul de la graine, constantes du projet. Intégrer le main.py et vérifier que tout s'exécute.	..expliquer la graine, l'algorithme, le rôle de chef, les tests de reproductibilité.
2	DAHA MEPA Marielle Sylvie	23V2241	Code génération des données	Coder une partie de 01_generation_donnees.py : création des 200 élèves,	expliquer les variables choisies, les

				génération de note_evaluation, heures_travail et orientation.	bornes, la logique de génération et pourquoi les données sont plausibles.
3	NKOH NDOGSI SHAWNA- WENDY	24G2588	Code nettoyage/export données	Compléter 01_generation_donnees.py : vérifier les valeurs, arrondir, sauvegarder en CSV, afficher un extrait représentatif.	expliquer le format du fichier CSV, les contrôles effectués et présenter 10 lignes d'exemple.
4	FANTCHOM SIMO JULIE SUZANNE	24G2546	Code Question 1	Coder 02_stat_univariee.py : moyenne, médiane, quartiles, écart-type, valeurs atypiques, histogramme, boxplot.	: expliquer les indicateurs, interpréter la distribution des notes et les valeurs atypiques.
5	WOLASSE KUEDJING STEVE ALFRED	24F2919	Code Question 2	Coder 03_stat_bivariee.py : nuage de points, corrélation, régression linéaire, prédiction de la note selon heures_travail.	expliquer le lien entre les deux variables, la droite de régression et les limites de l'anticipation.
6	DJOKO YIMDJIO MERVEILLE	25G2073	Code Question 3	Coder 04_clustering.py : standardiser les données, tester plusieurs nombres de groupes, appliquer K-means, décrire les profils.	expliquer la classification non supervisée, le nombre de groupes choisi et les profils obtenus.
7	CHOUPPO FOGAING Rudy Aubin	24G2708	Code Question 4	Coder 05_classification_supervisee.py : diviser les données, entraîner un modèle, calculer accuracy et matrice de confusion.	expliquer le modèle supervisé, la fiabilité et les risques pédagogiques d'une mauvaise orientation.
8	EPOLLE NJIMAN MARIETTE ERICKA	23V2417	Code visualisations + rapport	Coder 06_visualisations.py : centraliser les graphiques propres et exportables. Aider à insérer les figures dans le rapport.	expliquer les graphiques produits, leur utilité et les choix de présentation.
9	Miyebe Ariel	24G2895	Code tests +	Coder/compléter	expliquer les

	Fortune Napoléon		README + exécution	tests_execution.py et README.md : vérifier que tous les scripts fonctionnent, noter les commandes d'exécution.	tests, le mode d'emploi, les erreurs rencontrées et les corrections.
--	------------------	--	--------------------	--	--

8. Modèle obligatoire de documentation individuelle

Chaque étudiant doit créer un document de 1 à 2 pages maximum avec la structure suivante :

- Titre : Documentation individuelle — Nom Prénom — Matricule
- Rôle dans le groupe : préciser la partie du TP prise en charge.
- Fichier(s) de code réalisés : nom des fichiers et fonctions principales.
- Explication simple du code : décrire les étapes sans copier-coller tout le code.
- Résultat obtenu : tableau, valeur calculée, graphique ou capture de sortie.
- Difficultés rencontrées : bugs, choix méthodologiques, limites.
- Ce que je dois savoir expliquer à l'oral : 5 phrases maximum pour réviser.

9. Planning d'urgence sur deux jours

Moment	Travail à faire	Responsables
Jour 1 — Matin	Valider les variables, la graine, la structure des fichiers, créer le dépôt/dossier commun.	Chef + tous
Jour 1 — Milieu de journée	Coder la graine et la génération des données ; produire le CSV final.	KENGNE, DAHA, NKOH
Jour 1 — Après-midi	Coder les analyses Q1 et Q2 ; produire les premiers graphiques.	FANTCHOM, WOLASSE, EPOLLE
Jour 1 — Soir	Coder Q3 et Q4 ; commencer les documentations individuelles.	DJOKO, CHOUPO, MIYEBE
Jour 2 — Matin	Exécuter tous les scripts, corriger les erreurs, figer les résultats.	Tous
Jour 2 — Après-midi	Rédiger le rapport final avec figures, interprétations et limites.	EPOLLE + tous
Jour 2 — Soir	Vérification finale : dossier, README, rapport, noms, cohérence graine/données, préparation orale.	Chef + tous

10. Livrables finaux à produire

- Dossier nommé INF232_TP_GROUPEXX, à remplacer par le vrai numéro de groupe.
- Application complète : fichiers .py, dossier data/, dossier figures/, README.md.
- Fichier data/eleves_theme_D.csv généré avec la graine du groupe.

- Rapport final : thème choisi, génération de données, graine, méthodes, résultats, graphiques, interprétations, limites.
- Documentations individuelles des 9 membres.
- Vérification que le programme redonne exactement les mêmes données quand on le relance avec le même nom de chef.

11. Très important pour notre moyenne

- Personne ne doit copier le code d'un autre groupe : les données doivent venir de la graine du chef.
- Chaque graphique utilisé dans le rapport doit être produit par le code du groupe.
- Chaque résultat numérique cité dans le rapport doit venir des scripts exécutés.
- Chaque membre doit comprendre au moins les grandes lignes des quatre questions, car l'oral est aléatoire.
- Le chef vérifie la cohérence globale, mais chaque membre est responsable de sa partie.